

山东大学计算机科学与技术学院

大数据分析与实践课程实验报告

学号: 202320130203	姓名: 李姿含	班级: 数据 23
实验题目: 数据采样方法实践		
实验学时: 2	实验日期: 20250919	

实验目标:

本实验旨在实现多种数据采样和过滤方法，深入理解数据预处理过程中的数据清洗，数据过滤以及不同采样方式的原理与应用。

作品描述（实验背景、数据集来源、描述思路、实验背景）：

1、实验背景：

在大数据分析中，原始数据常存在空值、无效记录等问题，且直接分析全量数据易导致资源消耗大、效率低。数据清洗（如删除空行、条件过滤）是保障数据质量的关键步骤，而合理的采样方法能在减少数据量的同时，保留数据核心特征，为后续分析（如网络流量规律挖掘）提供高效支持。本实验围绕网络流量数据，开展数据清洗与多采样方法实践，为大数据预处理流程建立标准化认知。

2、数据集来源：

<http://storage.amesholland.xyz/data.csv>

数据集包含 10 个字段，分别记录源设备（from_dev）、源端口（from_port）、源城市（from_city）、源节点级别（from_level）、目标设备（to_dev）、目标端口（to_port）、目标城市（to_city）、目标节点级别（to_level）、流量（traffic）、带宽（bandwidth）信息。

3、描述思路：

①数据预处理：导入 pandas, numpy 库，使用 pd.read_csv 读取数据集，查看原始数据结构；调用 dropna(how='any') 删除含任意空值的行，解决空行问题；通过两次 loc[] 条件过滤（traffic!=0 和 from_level=='一般节点'），筛选出有效分析数据。

```
import pandas as pd
from C:\Users\86134\PycharmProjects\knn\venv\big_data_fenxi_lab1.py
import numpy as np
primitive_data=pd.read_csv("D:\\\\大三上学期\\\\大数据分析实践\\\\data.csv",encoding='gbk')
#print(primitive_data)

primitive_data_1=primitive_data.dropna(how='any')
#print(primitive_data_1)

data_before_filter=primitive_data_1
data_after_filter_1=data_before_filter.loc[data_before_filter["traffic"]!=0]
data_after_filter_2=data_after_filter_1.loc[data_after_filter_1["from_level"]=="一般节点"]
#print(data_after_filter_2)
```

②采样方法：

加权采样：根据目标节点级别（to_level）分配权重，一般节点 权重为 1，网络核心 权重为 5，通过 sample(n=50, weight='weight') 实现。

```

data_before_sample = data_after_filter_2
columns = data_before_sample.columns
weight_sample = data_before_sample.copy()
weight_sample['weight'] = 0
for i in weight_sample.index:
    if weight_sample.at[i, 'to_level'] == '一般节点':
        weight = 1
    else:
        weight = 5
    weight_sample.at[i, 'weight'] = weight
weight_sample_finish = weight_sample.sample(n=50, weights='weight')
weight_sample_finish = weight_sample_finish[columns]
#print(weight_sample_finish)

```

随机采样：直接使用 sample(n=50) 从过滤后的数据中随机抽取，保证每个样本被选中概率均等。

```

#随机抽样
random_sample = data_before_sample
random_sample_finish = random_sample.sample(n=50)
random_sample_finish = random_sample_finish[columns]
#print(random_sample_finish)

```

分层采样：按 to_level 分为一般节点(ybjd) 和网络核心(wlhx) 两层，分别抽取 17 和 33 个样本，再用 pd.concat() 合并，确保样本分层分布与总体一致。

```

#分层抽样
ybjd = data_before_sample.loc[data_before_sample['to_level'] == '一般节点']
wlhx = data_before_sample.loc[data_before_sample['to_level'] == '网络核心']
after_sample = pd.concat([ybjd.sample(17), wlhx.sample(33)])
print(after_sample)

```

结果图片：

1、原始数据读入：

	from_dev	from_port	from_city	...	to_level	traffic	bandwidth
0	47	71	通辽	...	网络核心	49636052613	1.000000e+11
1	47	74	通辽	...	网络核心	50056871412	1.000000e+11
2	47	240	通辽	...	网络核心	49453581081	1.000000e+11
3	47	241	通辽	...	网络核心	49733361585	1.000000e+11
4	47	242	通辽	...	一般节点	50492573662	1.000000e+11
...
1113	1129	546	上海	...	网络核心	48731433404	1.000000e+11
1114	1129	514	上海	...	一般节点	50060666120	1.000000e+11
1115	36036	499	长春	...	网络核心	50545082113	1.000000e+11
1116	36422	346	天津	...	网络核心	50628787089	1.000000e+11
1117	2701	619	大连	...	网络核心	48753971761	1.000000e+11

[1118 rows x 10 columns]

2、删除多余空行：

	from_dev	from_port	from_city	...	to_level	traffic	bandwidth
0	47	71	通辽	...	网络核心	49636052613	1.000000e+11
1	47	74	通辽	...	网络核心	50056871412	1.000000e+11
2	47	240	通辽	...	网络核心	49453581081	1.000000e+11
3	47	241	通辽	...	网络核心	49733361585	1.000000e+11
4	47	242	通辽	...	一般节点	50492573662	1.000000e+11
...
1113	1129	546	上海	...	网络核心	48731433404	1.000000e+11
1114	1129	514	上海	...	一般节点	50060666120	1.000000e+11
1115	36036	499	长春	...	网络核心	50545082113	1.000000e+11
1116	36422	346	天津	...	网络核心	50628787089	1.000000e+11
1117	2701	619	大连	...	网络核心	48753971761	1.000000e+11

3、进行过滤：

	from_dev	from_port	from_city	...	to_level	traffic	bandwidth
0	47	71	通辽	...	网络核心	49636052613	1.000000e+11
1	47	74	通辽	...	网络核心	50056871412	1.000000e+11
2	47	240	通辽	...	网络核心	49453581081	1.000000e+11
3	47	241	通辽	...	网络核心	49733361585	1.000000e+11
4	47	242	通辽	...	一般节点	50492573662	1.000000e+11
...
1097	2473	1460	吉林	...	一般节点	48409925693	1.000000e+11
1103	36036	18	长春	...	网络核心	48663350759	1.000000e+11
1104	63	6	通辽	...	一般节点	50355678076	1.000000e+11
1107	36036	52	长春	...	网络核心	49345226162	1.000000e+11
1115	36036	499	长春	...	网络核心	50545082113	1.000000e+11

[550 rows x 10 columns]

4、加权采样：

	from_dev	from_port	from_city	...	to_level	traffic	bandwidth
363	180	254	呼和浩特	...	网络核心	50252917820	1.000000e+11
52	96	157	呼和浩特	...	网络核心	50096366926	1.000000e+11
98	474	417	哈尔滨	...	网络核心	51874083489	1.000000e+11
300	63	70	通辽	...	网络核心	50635697563	1.000000e+11
75	180	84	呼和浩特	...	网络核心	49100967003	1.000000e+11
634	2473	769	吉林	...	网络核心	49319842054	1.000000e+11
292	63	6	通辽	...	网络核心	51392218854	1.000000e+11
18	63	10	通辽	...	网络核心	52195591947	1.000000e+11
804	180	264	呼和浩特	...	一般节点	49012460413	1.000000e+11
422	591	526	绥化	...	网络核心	48492868383	1.000000e+11
942	36036	52	长春	...	网络核心	49916177327	1.000000e+11
168	787	52	玉溪	...	网络核心	50468642387	1.000000e+11
393	474	1238	哈尔滨	...	网络核心	49693039378	1.000000e+11
100	474	422	哈尔滨	...	一般节点	48084671443	1.000000e+11
144	591	98	绥化	...	网络核心	50256295026	1.000000e+11
32	63	282	通辽	...	网络核心	49455678350	1.000000e+11
546	63	60	通辽	...	一般节点	47970715088	1.000000e+11
127	474	1399	哈尔滨	...	一般节点	50372436809	1.000000e+11
490	47	243	通辽	...	网络核心	50075073640	1.000000e+11
336	96	407	呼和浩特	...	网络核心	50219393940	1.000000e+11

5、随机抽样：

	from_dev	from_port	from_city	...	to_level	traffic	bandwidth
415	591	56	绥化	...	网络核心	47741796615	1.000000e+11
535	47	259	通辽	...	网络核心	51012708275	1.000000e+11
532	47	251	通辽	...	网络核心	51158383342	1.000000e+11
440	591	1290	绥化	...	网络核心	50090927530	1.000000e+11
68	180	30	呼和浩特	...	网络核心	49596659754	1.000000e+11
116	474	1227	哈尔滨	...	网络核心	48505909225	1.000000e+11
354	180	192	呼和浩特	...	一般节点	51828297117	1.000000e+11
329	96	159	呼和浩特	...	一般节点	51159730271	1.000000e+11
375	474	422	哈尔滨	...	网络核心	50424883915	1.000000e+11
443	787	52	玉溪	...	网络核心	49322809158	1.000000e+11
620	180	264	呼和浩特	...	网络核心	50207994896	1.000000e+11
74	180	52	呼和浩特	...	一般节点	49155371449	1.000000e+11
87	180	252	呼和浩特	...	一般节点	49137975001	1.000000e+11
306	63	278	通辽	...	网络核心	51091741717	1.000000e+11
993	36036	18	长春	...	网络核心	49826827167	1.000000e+11
54	96	159	呼和浩特	...	网络核心	51625089370	1.000000e+11
549	63	70	通辽	...	一般节点	49551919218	1.000000e+11
609	96	391	呼和浩特	...	网络核心	48978587445	1.000000e+11
487	47	240	通辽	...	网络核心	49873119534	1.000000e+11
168	787	52	玉溪	...	网络核心	50468642387	1.000000e+11

6、分层抽样：

	from_dev	from_port	from_city	...	to_level	traffic	bandwidth
847	47	252	通辽	...	一般节点	51065218921	1.000000e+11
151	591	586	绥化	...	一般节点	49061517661	1.000000e+11
828	47	314	通辽	...	一般节点	50910415109	1.000000e+11
924	2473	1043	吉林	...	一般节点	50311375989	1.000000e+11
674	591	586	绥化	...	一般节点	50565152517	1.000000e+11
498	47	314	通辽	...	一般节点	50043006782	1.000000e+11
447	787	63	玉溪	...	一般节点	49557001334	1.000000e+11
13	47	314	通辽	...	一般节点	50161220081	1.000000e+11
451	787	324	玉溪	...	一般节点	49843503409	1.000000e+11
423	591	558	绥化	...	一般节点	48364223310	1.000000e+11
157	591	1106	绥化	...	一般节点	50954337724	1.000000e+11
96	474	360	哈尔滨	...	一般节点	51819320173	1.000000e+11
548	63	66	通辽	...	一般节点	48141568100	1.000000e+11
780	96	391	呼和浩特	...	一般节点	50103206178	1.000000e+11
556	63	282	通辽	...	一般节点	49489299594	1.000000e+11
376	474	460	哈尔滨	...	一般节点	48394911971	1.000000e+11
404	474	1410	哈尔滨	...	一般节点	49488245045	1.000000e+11
344	180	34	呼和浩特	...	网络核心	50352242512	1.000000e+11
131	474	1473	哈尔滨	...	网络核心	53304989080	1.000000e+11
20	63	54	通辽	...	网络核心	49256234165	1.000000e+11
363	180	254	呼和浩特	...	网络核心	50252917820	1.000000e+11
57	96	379	呼和浩特	...	网络核心	49400869697	1.000000e+11
372	474	416	哈尔滨	...	网络核心	49544939922	1.000000e+11

372	474	416	哈尔滨	...	网络核心	49544939922	1.000000e+11
320	96	134	呼和浩特	...	网络核心	48498103572	1.000000e+11
442	787	51	玉溪	...	网络核心	50594027588	1.000000e+11
492	47	250	通辽	...	网络核心	49014089485	1.000000e+11
295	63	54	通辽	...	网络核心	49566827928	1.000000e+11
171	787	61	玉溪	...	网络核心	50063136706	1.000000e+11
889	63	12	通辽	...	网络核心	49823274555	1.000000e+11
1107	36036	52	长春	...	网络核心	49345226162	1.000000e+11
1059	47	252	通辽	...	网络核心	50358481161	1.000000e+11
326	96	156	呼和浩特	...	网络核心	50272713910	1.000000e+11
322	96	136	呼和浩特	...	网络核心	50541979348	1.000000e+11
341	180	26	呼和浩特	...	网络核心	48797633450	1.000000e+11
90	180	260	呼和浩特	...	网络核心	48006842653	1.000000e+11
587	96	141	呼和浩特	...	网络核心	47941844052	1.000000e+11
561	96	108	呼和浩特	...	网络核心	49739592973	1.000000e+11
77	180	98	呼和浩特	...	网络核心	50330801190	1.000000e+11
163	591	1284	绥化	...	网络核心	50187660151	1.000000e+11
317	96	123	呼和浩特	...	网络核心	50500915133	1.000000e+11
1041	180	20	呼和浩特	...	网络核心	50353235399	1.000000e+11
373	474	417	哈尔滨	...	网络核心	50339382092	1.000000e+11
105	474	474	哈尔滨	...	网络核心	49764093255	1.000000e+11
359	180	214	呼和浩特	...	网络核心	52204574667	1.000000e+11
563	96	114	呼和浩特	...	网络核心	51329552752	1.000000e+11
85	180	218	呼和浩特	...	网络核心	50106572586	1.000000e+11
1093	591	586	绥化	...	网络核心	47929885030	1.000000e+11
938	36036	18	长春	...	网络核心	47728327758	1.000000e+11
939	63	6	通辽	...	网络核心	49208374165	1.000000e+11
102	474	467	哈尔滨	...	网络核心	49987703744	1.000000e+11

[50 rows x 10 columns]